

Домашнее задание: анализ влияния AI-инструментов на академическую успеваемость

Тема: Алгоритм Random Forest. Перепессия Random Forest

Данные

<https://www.kaggle.com/datasets/laveshjadon/ai-impact-on-students>

1. Загрузка и первичный разведочный анализ

1. Загрузите и выведите первичный анализ:
 - a. Общую информацию о данных
 - b. Количество пропусков в каждом столбце
 - c. Описательную статистику для числовых признаков
 - d. Уникальные значения для категориальных признаков
2. Распределение целевых переменных
 - a. Постройте визуализации распределений для обеих целевых переменных: **Post_Semester_GPA**, **Burnout_Risk_Level**
3. Анализ связей признаков с целевыми переменными и между собой

2. Предобработка данных

1. Обработка пропусков и выбросов
 - a. Обработайте пропуски:
 - i. Для числовых признаков заполните медианой
 - ii. Для категориальных признаков заполните модой
2. Обнаружьте и обработайте выбросы с помощью метода IQR
3. Кодирование категориальных признаков
 - a. Для деревьев: используйте Label Encoding
 - b. Для линейных моделей и KNN: используйте One-Hot Encoding
 - c. Разделите категориальные признаки на группы: номинальные и порядковые

4. Создание новых признаков

- a. Создайте минимум 3 новых признака. Например:
- b. $AI_Usage_Ratio = Weekly_GenAI_Hours / Traditional_Study_Hours$
– соотношение использования AI и традиционного обучения
- c. $GPA_Change = Post_Semester_GPA - Pre_Semester_GPA$ (для анализа, не использовать как признак!)
- d. $Total_Study_Hours = Weekly_GenAI_Hours + Traditional_Study_Hours$ – общее время на учебу
- e. $AI_Efficiency = Pre_Semester_GPA * Weekly_GenAI_Hours$ – взаимодействие начального GPA и использования AI
- f. Обоснуйте, почему эти признаки могут быть полезны для предсказания.

3. Регрессия: предсказание Post_Semester_GPA

1. Метрики для оценки: R2, MSE, RMSE, MAE
2. Обучите **линейную** регрессию на масштабированных данных с One-Hot кодированием
3. Постройте график предсказанных vs реальных значений
4. Создайте **полиномиальные** признаки степени 2
5. Обучите линейную регрессию на полиномиальных признаках
6. Сравните метрики с обычной линейной регрессией
7. Обучите **KNN**: выберите оптимальное k от 1 до 30
8. Постройте график R2 в зависимости от
9. Обучите **деревья** с глубиной 5
10. Обучите Random Forest со 100 деревьями
11. Сравните метрики со всеми предыдущими моделями
12. (Дополнительно) Выполните GridSearchCV для подбора гиперпараметров

4. Классификация: предсказание Burnout_Risk_Level

1. Обучите DecisionTreeClassifier с глубиной 4
2. Обучите RandomForestClassifier со 100 деревьями

3. Выведите:

- a. Accuracy
- b. Матрицу ошибок (визуализируйте через `sns.heatmap`)
- c. Отчет по классификации (precision, recall, f1-score для каждого класса)

5. Кластеризация для генерации нового признака

1. Для кластеризации используйте следующие признаки:
 - a. Weekly_GenAI_Hours
 - b. Traditional_Study_Hours
 - c. Pre_Semester_GPA
 - d. Skill_Retention_Score
 - e. Prompt_Engineering_Skill
 - f. Perceived_AI_Dependency
2. Масштабируйте выбранные признаки
3. Определите оптимальное количество кластеров
4. Обучите K-Means с оптимальным k
5. Добавьте метку кластера в исходный датафрейм как новый признак
6. Переобучите лучшие модели (Random Forest для регрессии и классификации)
7. Сравните качество до и после добавления кластерного признака

Критерии оценки

- 1.0 : Все задания выполнены верно, код работает без ошибок.
- 0.5 : Выполнена половина заданий
- 0.0 : Выполнено меньше половины заданий либо код не работает